Домашнее задание 1

Персональные top-10 рекомендации комиксов и графических романов (Goodreads, Comics & Graphic)

Леонтьев Константин Валерьевич, МГУ ВМК, группа ММП517

1 ноября 2026

Аннотация

На подмножестве Goodreads *Comics & Graphic* (1,86 млн взаимодействий, 40,9 тыс. пользователей, 17,0 тыс. произведений) реализованы с нуля пять моделей: item-based KNN, iALS, EASE, факторизационная машина с метапризнаками и iALS с собственным целевым сигналом. Все модели сравниваются по одному протоколу с глобальным временным разбиением. Основная метрика — NDCG@10. Лучший результат на test показал EASE со взвешенным по давности профилем пользователя: **NDCG@10 = 0,1107**, в 3,4 раза выше популярности. Собственный таргет iALS (оценка × давность) поднимает NDCG@10 базового iALS с 0,0720 до 0,1025 (+42%). Метаданные в FM практически не дали прироста.

Содержание

1 Данные и постановка задачи **1**

2 EDA и подготовка данных **2**

3 Протокол оценки **3**

4 Модели **4**
4.1 Item-based KNN (`item_knn.py`) 4
4.2 iALS (`ials.py`) 4
4.3 EASE (`ease.py`) 5
4.4 Factorization Machine с метапризнаками (`fm.py`) 5
4.5 iALS с собственным целевым сигналом (`ials_custom.py`) 5

5 Результаты **6**
5.1 Подбор на validation 6
5.2 Финальное сравнение на test 7

6 Выводы **8**

7 Воспроизводимость **9**

1. Данные и постановка задачи

Источник. UCSD Book Graph, жанровое подмножество *Comics & Graphic* (M. Wan, J. McAuley, *Item Recommendation on Monotonic Behavior Chains*, RecSys 2018; M. Wan et al., *Fine-Grained Spoiler Detection from Large-Scale Review Corpora*, ACL 2019). Страница датасета: `https://mengtingwan.github.io/data/goodreads.html`; файлы скачиваются по публичным ссылкам `https://mcauleylab.ucsd.edu/public_datas`

ets/gdrive/goodreads/byGenre/: goodreads_interactions_comics_graphic.json.gz и goodreads_books_comics_graphic.json.gz.

Поля. Взаимодействия — записи «полок» пользователя: user_id, book_id, is_read (отмечено прочитанным), rating (0 — без оценки, 1–5 звёзд), review_text_incomplete (текст рецензии), date_added (момент добавления на полку). Метаданные изданий: название, авторы, издатель, формат, язык, год, число страниц, work_id (произведение, объединяющее издания), пользовательские теги-полки.

Что рекомендуем и что релевантно. Рекомендуем *произведения*, которые пользователь добавит на полку в ближайший месяц. Объект **релевантен** на test, если пользователь добавил его в целевой период и *не* поставил 1–2 звезды. Добавление «хочу прочитать», прочтение без оценки и оценки 3–5 — положительные исходы, а 1–2 звезды («did not like it», «it was ok») означают неудачную рекомендацию. Этот критерий общий для всех моделей: обучающие таргеты моделей его не меняют.

2. EDA и подготовка данных

Качество данных. В исходных 7,35 млн записях нет непарсящихся дат, дат раньше запуска Goodreads (2007), явных дубликатов (user, book) и книг без метаданных. Без оценки 38,6% записей, прочитанными отмечено 64,8%, рецензия есть у 7,4%. Оценки смещены вверх, 1–2 звезды редки (рис. 1). В метаданных пропущены издатель (21,7%), формат (24,3%), язык (33,1%), число страниц (26,6%) и год (20,7%). Авторы и теги-полки есть у всех книг. Число добавлений растёт до 2016–2017 гг. и обрывается в начале ноября 2017 (момент сбора данных), поэтому последний полный месяц — октябрь 2017.

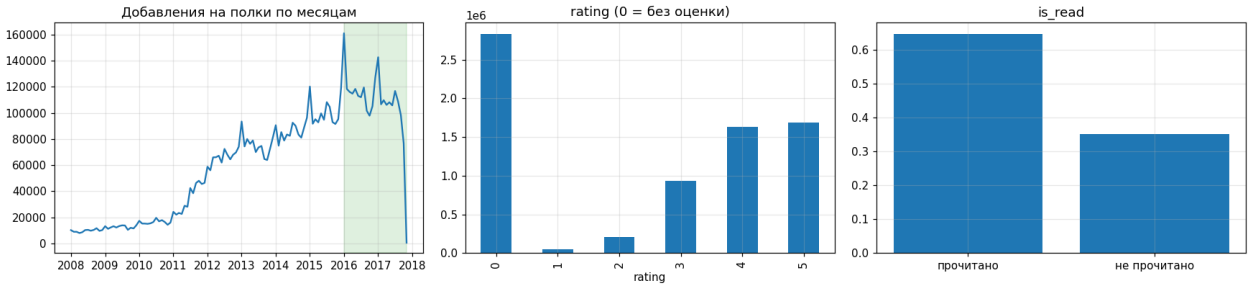


Рис. 1: Добавления на полки по месяцам (зелёным — выбранное окно), распределение оценок и доля прочитанного.

Очистка и подвыборка. Шаги и их объём — в табл. 1.

1. Окно date_added $\in$ [2016-01-01, 2017-11-01). Это актуальная, более стационарная часть данных. С ней итоговый объём укладывается в лимит 2 млн без случайного прореживания пользователей.
2. Издания $\rightarrow$ произведения (work_id). Разные издания одной книги считаются одним объектом: берём первое добавление, максимальную оценку и логическое «или» по is_read и рецензии. Иначе модель рекомендовала бы «уже прочитанное» в другом издании. Для 0,33% записей у пользователя уже было другое издание того же произведения.
3. Итеративное k-core: пользователи ≥ 10, произведения ≥ 20 взаимодействий. Фильтр убирает шум и даёт каталог, при котором плотная матрица items $\times$ items для EASE помещается в память.

Таблица 1: Формирование выборки.

Шаг	Взаимодействий	Пользователей	Объектов
Исходные данные	7 347 630	342 415	89 411
Временное окно 2016-01 – 2017-10	2 486 080	178 141	79 715
Издания → произведения	2 480 720	178 141	58 497
k-core (user ≥ 10, item ≥ 20)	**1 855 094**	**40 907**	**16 960**

Плотность итоговой матрицы — 0,27% (разреженность 99,73%). Хвост популярности умеренный: топ-1% произведений собирает 19,4% взаимодействий, топ-10% — 51,8% (рис. 2).

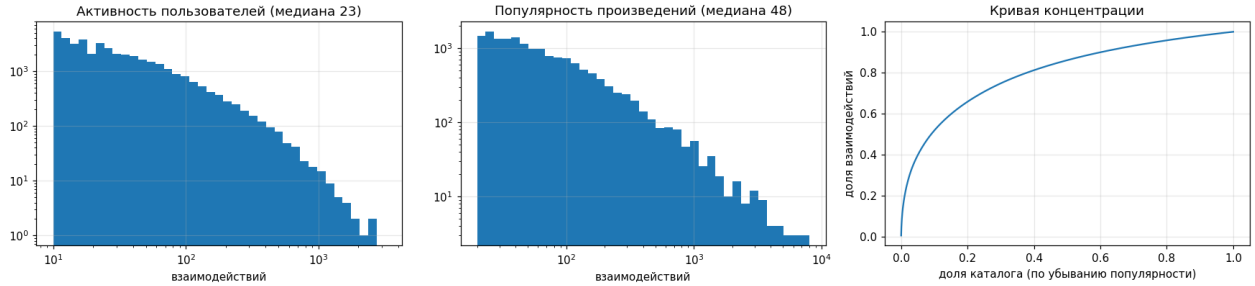


Рис. 2: Активность пользователей, популярность произведений (log-log) и кривая концентрации.

Метаданные. 68,8% произведений каталога входят в серии: манга и комиксы выходят томами. В каталоге 6 872 автора и 1 324 издателя. Пользовательские полки дают жанровые теги (`manga`, `graphic-novels`, `superheroes`, `marvel`, `dc`, `horror`, …). Служебные полки (`to-read`, `owned`, `2016-reads`, `kindle`, …) отфильтрованы регулярным выражением. Агрегаты `average_rating`, `ratings_count`, `similar_books` посчитаны на момент сбора данных, то есть после test, поэтому в признаки не взяты. Популярность для FM считается только по истории.

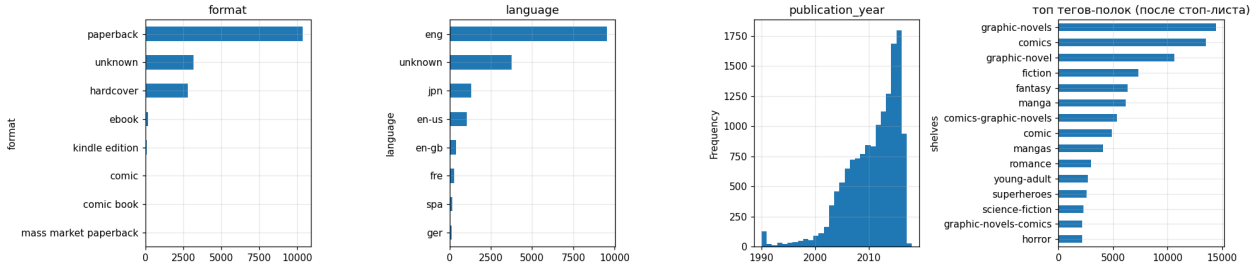


Рис. 3: Метаданные каталога: формат, язык, год издания, самые частые теги после стоп-листа.

3. Протокол оценки

- **Глобальное временное разбиение.** Train — `date_added` < 2017-09-01, validation — сентябрь 2017, test — октябрь 2017. Гиперпараметры подбираются на validation (обучение на train). Затем каждая модель переобучается с выбранными параметрами на train+validation и один раз оценивается на test.
- **Кандидаты** — весь каталог произведений, встречавшихся в истории. Объекты, впервые появившиеся в целевом периоде, не может порекомендовать ни одна коллаборативная модель, поэтому они исключаются из ground truth (0,12% строк validation, 0,25% строк test).

- **Пользователи** — все, у кого есть история и хотя бы один релевантный объект в целевом периоде. Набор одинаков для всех моделей. Холодные пользователи (10,1% и 7,9% строк) не оцениваются: для них нужен популярностный fallback.
- **Исключение известного:** всё, что уже есть на полке пользователя, удаляется из кандидатов и из ground truth.

Таблица 2: Разбиения.

	Validation	Test
История: взаимодействий	1 727 778	1 799 821
Пользователей / объектов (кандидатов)	40 504 / 16 949	40 771 / 16 956
Взаимодействий в целевом периоде	72 043	55 273
Оцениваемых пользователей	12 781	11 285
Релевантных на пользователя (среднее)	4,94	4,40

Метрики (бинарная релевантность, $K = 10$; основная метрика выбрана до подбора):

- **NDCG@10** (основная). Учитывает порядок в коротком списке: верхние позиции ленты из 10 рекомендаций видят чаще всего. $\text{NDCG@}K = \frac{1}{\text{IDCG}} \sum_{k=1}^{K} \frac{\mathbb{1}[i_k \in R_u]}{\log_2(k+1)}$, где $\text{IDCG} = \sum_{k=1}^{\min(|R_u|,K)} \frac{1}{\log_2(k+1)}$.
- **Recall@10** $= |\text{top}_{10} \cap R_u| / \min(|R_u|, 10)$ — какая доля будущих добавлений покрыта списком.
- Вспомогательные: **HR@10** (хотя бы одно попадание), **MAP@10**, **Coverage@10** (доля каталога в списках) и **Novelty@10** ($-\log_2$ доли популярности) для контроля перекоса в популярное.

Ориентир — популярность: за всю историю NDCG@10 = 0,0326, за последние 30 дней — 0,0368 (validation).

4. Модели

Обучение, предсказание и формирование рекомендаций реализованы с нуля на NumPy, SciPy и PyTorch; код — в директории `models/`. Каждая модель реализует `fit(...)` и `score(users)`. Top-K с маскированием известного считается общей функцией.

4.1. Item-based KNN (`item_knn.py`)

Асимметричный косинус со сжатием на бинарной матрице X (опционально с IUF-весами пользователей $1/\sqrt{\log(1 + |I_u|)}$):

$$\text{sim}(i,j) = \frac{x_i^\top x_j}{\|x_i\|^{2\alpha}\, \|x_j\|^{2(1-\alpha)} + \lambda_{\text{shrink}}}.$$

Для каждого j остаются k ближайших соседей, сходства возводятся в степень p. Скор: $\hat{s}_{uj} = \sum_{i \in I_u} r_{ui}\, \text{sim}(i,j)^p$. Профиль r_{ui} при формировании рекомендаций либо бинарный ($h = \infty$), либо взвешенный по давности: $r_{ui} = 2^{-\Delta t_{ui}/h}$, где Δt — дни от добавления до конца истории. Поиск (поэтапно): $k \in \{20, 50, 100, 200\}$, $\lambda_{\text{shrink}} \in \{0, 10\}$, $p \in \{1, 2, 3\}$, $\alpha \in \{0{,}5; 0{,}7\}$, IUF, $h \in \{\infty, 30, 90, 180, 365\}$.

4.2. iALS (`ials.py`)

Hu, Koren, Volinsky (2008) с регуляризацией, масштабируемой частотой (Rendle et al., 2022):

$$L = \sum_{(u,i)\in S} c_{ui}\,(p_{ui} - x_u^\top y_i)^2 + w_0 \sum_{(u,i)\notin S} (x_u^\top y_i)^2 + \sum_u \lambda_u \|x_u\|^2 + \sum_i \lambda_i \|y_i\|^2, \quad \lambda_u = \lambda\,(|S_u| + w_0|I|)^\nu.$$

В базовой модели $p_{ui} = 1$, $c_{ui} = 1 + \alpha$, $w_0 = 1$. Шаг ALS для пользователя:

$$\Big(w_0 Y^\top Y + \sum_{i\in S_u} (c_{ui} - w_0)\, y_i y_i^\top + \lambda_u I\Big) x_u = \sum_{i\in S_u} c_{ui}\, p_{ui}\, y_i.$$

Системы всех пользователей решаются одновременно тремя шагами сопряжённых градиентов с тёплым стартом (одно умножение стоит $O(\text{nnz}\cdot f)$), затем так же для объектов, 15 итераций. Поиск: $f \in \{128, 256, 512\}$, $\alpha \in \{1, 5, 20\}$, $\nu \in \{0, 1\}$ с соответствующими сетками λ.

4.3. EASE (`ease.py`)

Steck (2019): $\min_B \|X - XB\|_F^2 + \lambda\|B\|_F^2$ при $\text{diag}(B) = 0$. Решение в замкнутой форме: $P = (X^\top X + \lambda I)^{-1}$, $B_{ij} = -P_{ij}/P_{jj}$, $B_{jj} = 0$, скор $\hat{s}_u = x_u B$. Поиск: $\lambda \in \{50, \dots, 3200\}$, профиль x_u при формировании рекомендаций — бинарный или по давности, $h \in \{\infty, 30, 90, 180, 365\}$; матрица B при этом не меняется.

4.4. Factorization Machine с метапризнаками (`fm.py`)

Пара (пользователь, произведение) кодируется разреженным вектором $x = [x^U; x^I]$:

- пользователь: `user_id`; мешок последних 200 произведений истории с весами $1/\sqrt{n}$; бакеты активности, доли оценённого, средней оценки и давности последнего действия (по train);
- произведение: `item_id`; до 3 авторов; серия (из названия); издатель; до 10 тегов-полок; формат; язык; год; число страниц; e-book; «в серии»; популярность за всю историю и за 30 дней (по train).

Все признаки доступны в момент рекомендации. Модель второго порядка:

$$\hat{y}(x) = w_0 + \sum_j w_j x_j + \tfrac{1}{2} \sum_f \Big[\big(\textstyle\sum_j v_{jf} x_j\big)^2 - \sum_j v_{jf}^2 x_j^2 \Big].$$

Если разделить суммы на пользовательскую и объектную части ($s_u = \sum_{j\in U} v_j x_j$, $s_i = \sum_{j\in I} v_j x_j$), получим $\hat{y}(u,i) = \text{const}_u + \text{lin}(i) + \text{pair}(i) + \langle s_u, s_i\rangle$. Поэтому скоринг всего каталога сводится к одному матричному произведению. Обучение: на каждый батч сэмплируется 1024 общих равномерных негатива, функция потерь — sampled softmax (или BPR) с L_2. Целевой объект исключается из мешка истории (leave-one-out контекст, как в FISM). Поиск: $f \in \{64, 128\}$, lr $\in \{5\cdot 10^{-4}, 10^{-3}\}$, $L_2 \in \{0; 0{,}01; 0{,}1\}$, softmax/BPR, 5–20 эпох.

4.5. iALS с собственным целевым сигналом (`ials_custom.py`)

Базовый iALS регрессирует каждую наблюдаемую пару в одно и то же $p_{ui} = 1$. Предлагаемый таргет учитывает, *что* и *когда* пользователь сказал о книге (r — звёзды, Δt — дни до конца истории):

$$g(r) = \begin{cases} 0, & r \in \{1, 2\} \text{ (явный негатив)} \\ \max\big(0,\ 1 + \gamma\,\frac{r-3{,}5}{1{,}5}\big), & r \in \{3, 4, 5\} \\ 1, & r = 0 \end{cases}$$

$$d(\Delta t) = \beta + (1-\beta)\,2^{-\Delta t/h}, \qquad p_{ui} = g(r_{ui})\,d(\Delta t_{ui}).$$

Обоснование. Предсказываем ближайший месяц, а вкусы в комиксах дрейфуют (серии заканчиваются, выходят новые тома). Поэтому недавнее добавление должно сильнее тянуть x_u к y_i, а пол β не даёт полностью забыть давнюю историю. Оценка 5 сильнее оценки 3. Оценки 1–2 остаются *наблюдаемой* парой с целью 0 и уверенностью $1+\alpha$, то есть становятся уверенным негативом, а не просто «неизвестным». Уверенность, решатель и функция потерь совпадают с базовым iALS: отличается *только* цель p_{ui}. При $\gamma = 0$, $\beta = 1$ и без правила дизлайков модель совпадает с базовой. Гиперпараметры факторизации берутся у лучшего базового iALS. Подбираются $h \in \{30, 90, 180, 365\}$, $\beta \in \{0{,}1; 0{,}3; 0{,}6\}$, $\gamma \in \{0; 0{,}5; 1\}$.

5. Результаты

5.1. Подбор на validation

iALS. Сильнее всего на качество влияет размерность. Уверенность и регуляризация влияют слабо: лучшее $\alpha = 1$, частотная регуляризация ($\nu = 1$) примерно равна постоянной.

Таблица 3: iALS: размерность ($\alpha = 1$, $\nu = 1$, $\lambda = 10^{-3}$), validation.

f	NDCG@10	Recall@10	Coverage@10
128	0,0647	0,0903	0,178
256	0,0704	0,0988	0,252
512	**0,0769**	**0,1090**	0,339

Профиль по давности в ItemKNN и EASE. Лучшие «чистые» конфигурации: ItemKNN с $k = 20$, $p = 2$, IUF (NDCG@10 = 0,0800) и EASE с $\lambda = 200$ (0,0831). Взвешивание профиля по давности при формировании рекомендаций даёт +37–40%.

Таблица 4: Влияние периода полураспада h профиля пользователя, NDCG@10 на validation.

	$h = \infty$	$h = 30$	$h = 90$	$h = 180$	$h = 365$
ItemKNN ($k = 20$, $p = 2$, IUF)	0,0800	**0,1096**	0,1072	0,1000	0,0915
EASE ($\lambda = 200$)	0,0831	0,1121	**0,1162**	0,1117	0,1019

FM: абляция признаков. Почти весь выигрыш над MF даёт мешок истории. Метаданные прироста не дают. Из гиперпараметров важны softmax вместо BPR (0,0614 против 0,0504) и умеренный lr. При lr = $3 \cdot 10^{-3}$ в предварительном запуске модель заметно переобучалась.

Таблица 5: FM ($f = 64$, lr $= 10^{-3}$, softmax, 10 эпох), validation.

Признаки	NDCG@10	Recall@10
ID + история + метаданные	**0,0614**	**0,0917**
ID + история	0,0613	0,0896
ID + метаданные	0,0488	0,0750
Только ID (MF)	0,0516	0,0749

iALS с собственным таргетом. Лучшие параметры: $h = 180$ дней, $\beta = 0{,}1$, $\gamma = 1$. Абляция по единому протоколу (табл. 6) показывает, что давность и оценка дополняют друг друга. Градация оценок (γ: 0 → 0,5 → 1 даёт 0,0959 → 0,1019 → 0,1048) добавляет качество сверх

одной давности. Цена — смещение к актуальным объектам: Coverage@10 падает с 0,34 до 0,26.

Таблица 6: Абляция таргета iALS ($f = 512$, $\alpha = 1$, $\nu = 1$, $\lambda = 10^{-3}$), validation.

Таргет p_{ui}	NDCG@10	Recall@10	Coverage@10
Базовый iALS ($p = 1$)	0,0769	0,1090	0,339
Только давность $d(\Delta t)$	0,0955	0,1277	0,196
Только оценка $g(r)$	0,0815	0,1130	0,358
Полный таргет $g(r)\, d(\Delta t)$	**0,1048**	**0,1364**	0,259

5.2. Финальное сравнение на test

Таблица 7: Test (октябрь 2017, 11 285 пользователей), $K = 10$. Модели переобучены на train+validation.

Модель	NDCG	Recall	HR	MAP	Coverage	Novelty	val NDCG
EASE	**0,1107**	**0,1472**	**0,2730**	0,0775	0,537	11,47	0,1162
ItemKNN	0,1039	0,1249	0,2144	**0,0796**	**0,751**	**12,73**	0,1096
iALS-custom	0,1025	0,1331	0,2480	0,0727	0,246	11,27	0,1048
iALS	0,0720	0,1004	0,1903	0,0489	0,332	11,75	0,0769
FM (meta)	0,0526	0,0794	0,1664	0,0322	0,494	11,04	0,0614
Popularity (30 дней)	0,0325	0,0494	0,1132	0,0191	0,002	10,38	0,0368

Таблица 8: Выбранные гиперпараметры.

Модель	Параметры
ItemKNN	$k = 20$, $\lambda_{\text{shrink}} = 0$, $\alpha = 0{,}5$, $p = 2$, IUF, профиль по давности $h = 30$ дней
iALS	$f = 512$, $\alpha = 1$, $\nu = 1$, $\lambda = 10^{-3}$, 15 итераций, 3 шага CG
EASE	$\lambda = 200$, профиль по давности $h = 90$ дней
FM	все признаки, $f = 64$, lr $= 10^{-3}$, $L_2 = 0$, sampled softmax (1024 негатива), 10 эпох, батч 4096
iALS-custom	как iALS; $h = 180$ дней, $\beta = 0{,}1$, $\gamma = 1$, дизлайки $\rightarrow$ цель 0

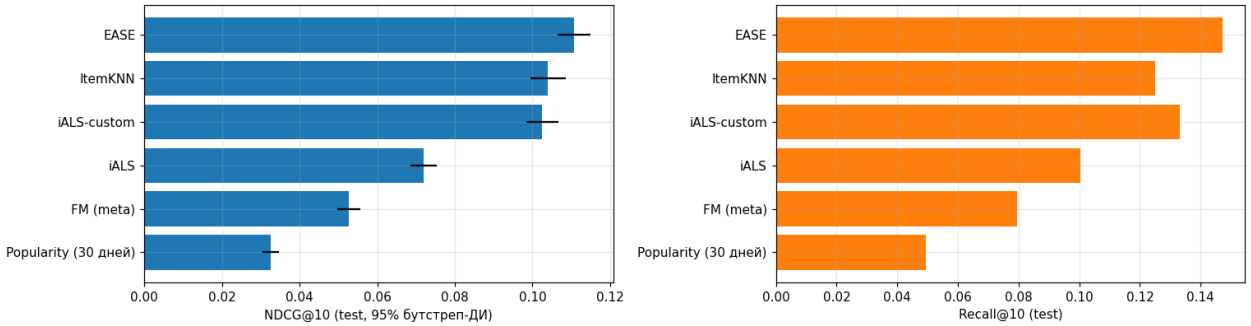


Рис. 4: NDCG@10 (с 95% бутстреп-интервалами) и Recall@10 на test.

Надёжность различий. Парный бутстреп по пользователям (2000 повторов): все отличия EASE от остальных моделей значимы.

Таблица 9: Парный бутстреп, разность NDCG@10 на test.

Сравнение	ΔNDCG@10	95% ДИ
EASE − ItemKNN	0,0068	[0,0043; 0,0092]
EASE − iALS-custom	0,0082	[0,0053; 0,0112]
EASE − iALS	0,0387	[0,0356; 0,0420]
EASE − FM	0,0581	[0,0542; 0,0621]
EASE − Popularity	0,0782	[0,0735; 0,0829]

Таблица 10: NDCG@10 на test по активности пользователя в истории.

История	EASE	ItemKNN	iALS-custom	iALS	FM	Pop	Польз.
10–20	**0,122**	0,109	0,115	0,094	0,076	0,036	3 762
21–50	**0,114**	0,108	0,104	0,075	0,050	0,033	3 438
51–150	**0,100**	0,094	0,092	0,055	0,038	0,031	2 937
> 150	0,092	**0,100**	0,084	0,032	0,022	0,024	1 148

6. Выводы

1. **Лучший метод — EASE** (NDCG@10 = 0,1107 на test, в 3,4 раза выше популярности). Порядок моделей на test совпадает с порядком на validation. Значения на test немного ниже, потому что в октябре меньше релевантных объектов на пользователя. Признаков переобучения подбора на validation нет.
2. **Item-item модели сильнее факторизаций на этих данных.** Комиксы читают сериями, и сигнал «следующий том / та же вселенная» хорошо ловится совместной встречаемостью. ItemKNN лучше всего работает с короткими и «острыми» соседствами ($k = 20$, $p = 2$). Его списки самые разнообразные (Coverage@10 = 0,75), и у него наибольший MAP@10, но попадает он реже EASE (HR@10 0,214 против 0,273). Для самых активных читателей (> 150 взаимодействий) ItemKNN лучший.
3. **Время — главный источник качества.** Взвешивание профиля по давности (сами модели не меняются) улучшает EASE и ItemKNN на 37–40%. Собственный таргет iALS (+36% на validation, +42% на test) переносит ту же идею в обучение. Абляция показывает, что давность и оценка дополняют друг друга. Сильная градация оценок ($\gamma = 1$) и уверенные негативы для 1–2 звёзд дают прирост сверх одной давности.
4. **Базовый iALS** упирается в размерность (128 → 512 факторов: 0,065 → 0,077) и сильно деградирует у активных пользователей (0,094 → 0,032). Один вектор усредняет широкий вкус. Таргет с давностью частично это исправляет.
5. **Метаданные в FM почти не помогли** (0,0614 против 0,0613 без них). Выигрыш FM над MF даёт мешок истории. У тёплых объектов (k-core ≥ 20) коллаборативного сигнала достаточно, а в метаданных много пропусков и шумных тегов. Контент полезен прежде всего для холодных объектов, которых по протоколу почти нет (0,25% строк test). FM также не использует время, поэтому уступает моделям с давностью.

Ограничения.

- Одно глобальное временное разбиение (validation — сентябрь, test — октябрь 2017) и один жанр. Доверительные интервалы учитывают только разброс по пользователям, но не по периодам.

- k-core фильтрация считалась на всём окне, включая validation и test. Это мягкий отбор «выживших» пользователей и объектов — стандартная практика, но не строго онлайн-постановка.
- Теги-полки — срез на момент сбора данных (2017). Агрегаты с явной утечкой исключены, а на вывод о метаданных теги не повлияли.
- Переводы и национальные издания одной серии на Goodreads часто являются разными произведениями. Критерий релевантности точный по произведению, поэтому рекомендация перевода считается промахом. Объединение переводов, вероятно, подняло бы все метрики.
- Холодные пользователи и новые объекты не оцениваются. Поиск гиперпараметров поэтапный и ограничен бюджетом Colab T4: iALS до 512 факторов, у FM небольшая сетка и равномерные негативы.

7. Воспроизводимость

Репозиторий, директория `hw1`: `experiments.ipynb` (основной ноутбук с выполненными ячейками), `models/` (`item_knn.py`, `ials.py`, `ease.py`, `fm.py`, `ials_custom.py`, общие `common.py` и `data.py`), `DATA.md`, `requirements.txt`, `.gitignore`. Данные скачиваются автоматически функцией `models.data.download()` и в репозиторий не попадают. Все зёрна (`seed = 42`) и параметры зафиксированы в ячейке `CONFIG`. Ноутбук выполняется сверху вниз. Полный прогон на Google Colab (GPU Tesla T4) занял около 50 минут.